Kotoba-VLA：日本語の声で頼める VLA ロボット

PARC2026 で分かった「VLA は言い回しに弱い」を、LLM による“言葉の通訳”で解く

Physical AI 応用編1 最終課題 ／ omnicampus アカウント：Masuhama1946
動画：（omnicampus の指定フォームで提出。タイトル PAI最終課題_Masuhama1946） ／ コード：https://github.com/masuhama2147-svg/kotoba-vla

1. 概要

日本語の音声で頼んだ作業を、シミュレータ LIBERO（robosuite / MuJoCo）上のロボットアームが VLA（視覚言語行動モデル）π0.5 で実行するシステムを作った。 VLA は学習時に見た言い回しから外れると急に失敗するため、依頼を **VLA が学習時に見た文（正準文）へ翻訳する「言語ブリッジ」**を間に挟んだ。 言語ブリッジは音声認識（Whisper）・多言語埋め込み検索・LLM（Qwen3-8B）で構成し、すべて Mac 上でローカルに動く。 複数の作業をまとめた依頼は、LLM がスキルの列に分解し、1 つずつ実行してゴール達成を確かめる。 スキル選択は調整に使っていない依頼文でも文字入力で 100%・音声入力で 95% 正しく、 VLA に渡す言葉をそろえることで、遠回しな依頼で起きていた「別の作業をしてしまう」失敗がなくなった。

74% → 90%
遠回しな英語の依頼での VLA 成功率
（そのまま → Kotoba-VLA、各 90 試行、p=0.009）

25 → 0 件
頼んでいない別の作業をしてしまった失敗
（英語の言い換え＋日本語の英訳、計 180 試行）

3 → 14 / 18
複数ステップ依頼の完遂
（そのまま連続実行 → 姿勢復帰＋再試行）

2. 目的と背景 — PARC2026 から持ち込んだ問い

筆者は VLA 開発コンペ PARC2026 に参加し、π0.5 を LIBERO 系のタスクで動かして本番評価を受けた。そこで次の事実を測っている。

PARC2026 本番で測った事実	示唆
指示文を小文字にする 1 行の変更だけで、Track1 のスコアが 0.179 → 0.382	VLA は学習時の言い回し（全文小文字の 40 文）から外れると急に弱くなる
「ramekin の上の器」を取る課題で、20 回中 19 回は別の器を運んだ	言葉と物体の対応づけに失敗すると、別の作業を自信満々に実行する
同じ重みでも推論の乱数を固定しないとスコアが 1.76 倍ぶれた	比較は乱数を固定し、同じ条件で行う必要がある

人が実際にロボットへ頼むときの言葉は、日本語で、遠回しで、複数の作業を含む。これを学習済みの VLA にそのまま（あるいは機械的に英訳して）渡すと性能が落ちるはずである。 実際、本課題で日本語の依頼を LLM で英訳したところ、学習時の文と一致したものは **30 文中 0 文**だった。 （後で示すとおり、素直な依頼なら π0.5 は英訳でも多くをこなすが、依頼が遠回しになると別の作業をしてしまう。） そこで本課題の目的を「VLA を再学習せずに、人の言葉を VLA に通じる言葉へ変換し、複数の作業を安全にやり切らせる」とした。

3. システム



失敗したら初期姿勢へ戻して 1 回だけ再試行

3.1 言語ブリッジ（音声認識・検索・LLM 計画）

- **音声認識**：Whisper large-v3-turbo（mlx-whisper）。平均 0.3 秒。
- **スキル検索**：各スキルの正準文と、PARC2026 で集めた LIBERO-plus の言い換え 2,052 文（40 スキル × 約 51 文）を検索キーにし、Qwen3-Embedding-0.6B で依頼に近いスキルを並べる。
- **LLM 計画**：Qwen3-8B（MLX 4bit）に、シーンにある物体の日本語の説明と、検索順のスキル一覧（ID・正準文・言い換え例）を見せ、**スキル ID の列だけ**を JSON で返させる。 出力は検証し、一覧に無い ID なら理由を添えて再生成させる。VLA に渡る文字列は必ず正準文になるため、言い回しの揺れが VLA に届かない。 実行できない依頼（例：「冷蔵庫から牛乳を出して」）は、近いスキルに丸めずに断る。平均 3.2 秒。

3.2 VLA 実行 — PARC2026 最終提出モデルの再構成

VLA には、PARC2026 本選 Track1 の最終提出と同じ重みを使った。公開されている π0.5（`lerobot/pi05_libero_finetuned_v044`）に、 PARC2026 で LIBERO-plus を使って自作した LoRA（rank 16、38 モジュール）を係数 0.1 で焼き込んだもので、手元で再構成した重みの SHA-256 は 提出物の記録 `126d63db21429a1c…` と**一致した**。 推論経路も提出時のもの（画像 256px、LIBERO の観測前処理、`n_action_steps=12`）をそのまま使い、PARC で 0 点を出した落とし穴 （重みが黙って読み込まれない、正規化統計が空で素通しになる）を起動時に値で検査する。Apple GPU（MPS）では fp32 で動かし、12 行動ぶんの推論が 0.74 秒。

3.3 検証と回復

各スキルの成否は LIBERO の BDDL ゴール述語（例：`On(bowl, plate)`）で毎ステップ判定する。LIBERO-Goal の 10 スキルは物体と配置が共通でゴールだけが異なるので、 ゴール述語を差し替えれば同じシーンで複数のスキルを連続実行・判定できる。安全指標として、PARC の採点と同じく「対象外の物体が 1mm 以上動いたか」も測る。 VLA は初期姿勢から学習しているため、次のスキルの前にアームを初期姿勢へ戻し（OSC の差分指令による P 制御）、失敗したら戻してから 1 回だけ再試行する。

3.4 プロセス構成

VLA（transformers 5.3 / lerobot 0.5.2）とシミュレータ（Python 3.10 / robosuite 1.4 / numpy 1.26）は同じ Python 環境に同居できない（PARC で実測）。 そこで AI・VLA・シミュレータの 3 プロセスに分け、観測と行動を msgpack で HTTP 越しに受け渡した。ROS 2 でノードを分けるのと同じ考え方である。

4. 実験

4.1 言語ブリッジの正解率

LIBERO-Goal の 10 スキルについて、日本語の依頼文を開発セット（1 スキル 3 通り＋複数ステップ 6 件＋実行不可 3 件）と、 プロンプト調整の後に新しく書いた未使用セット（1 スキル 2 通り＋複数ステップ 4 件＋実行不可 2 件）に分けた（PARC で学んだ「選抜と確証は別のセットで」）。 音声入力は、macOS の音声合成で読み上げた音声を Whisper に通した結果を使った。

セット・入力	件数	検索のみ（正準文）	検索のみ（＋言い換え）	LLM 計画	複数ステップ完全一致	実行不可を断れた	英訳が正準文と一致
開発・文字	30	80%	80%	**100%**	100%	100%	0%
開発・音声	30	87%	80%	**100%**	100%	100%	3%
未使用・文字	20	80%	80%	**100%**	100%	100%	0%
未使用・音声	20	80%	80%	**95%**	100%	100%	0%

LLM 計画は未使用セットでも文字入力で 100%（20/20）、音声入力で 95%（19/20）のスキルを正しく選び、複数ステップの依頼はすべて正しい順序に分解し、実行できない依頼はすべて断った。唯一の誤りは、音声認識が「ボウルを皿に重ねて」を「ボールをさらに重ねて」と聞き取った例で、この場合も無理にスキルへ当てはめず「できない」と返した（安全側の失敗）。検索だけで 1 位を選ぶと 80% に留まり、言い換えを検索キーに足しても日本語の依頼では改善しなかった。一方、英語の言い換え 515 文を自分自身を除いて検索すると、1 位の正解率は正準文だけで 94.8%、言い換え込みで 97.5% となり、誤りが約半分に減った。言い換えプールは英語の遠回しな表現に効き、日本語は LLM の判断が主役という役割分担である。LLM を Qwen2.5-0.5B に替えると単一スキルの正解率は 23%、複数ステップと断りは 0% に落ちたため、この役割には数 B 規模のモデルが必要だった。なお開発セットでの最初のプロンプトは 90%（文字）／83%（音声）で、誤りの原因（「棚」がキャビネットかラックか、依頼に無いステップの付け足し、音声認識の誤変換）を見てシーンの物体の説明と規則を加えた。未使用セットはその後に作り、調整には使っていない。

4.2 渡す言葉による VLA の成功率

同じスキル・同じ初期状態（各スキル 3 通り）・同じ乱数で、VLA に渡す文だけを変えた。乱数を固定しているので、同じ文・同じ初期状態なら結果も同じになる（決定論）。 英語の言い換えを言語ブリッジに通す条件では、評価に使う言い換え文を検索キーと LLM への例文から外した（答えを見ながら検索しないため）。

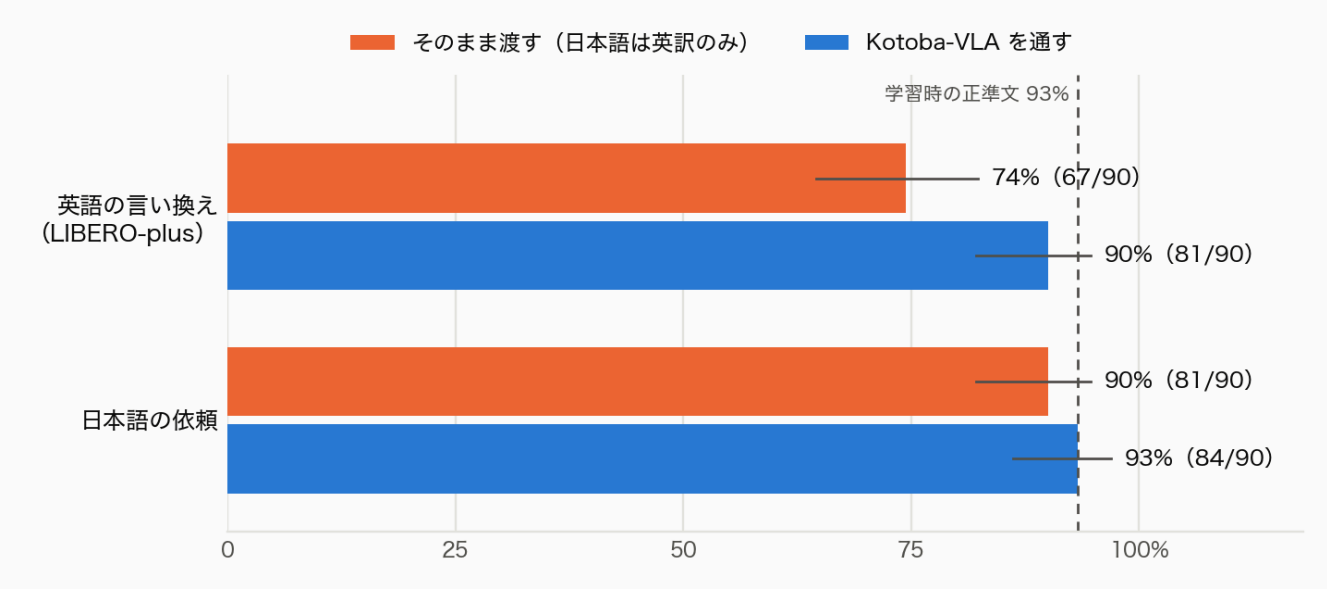


図 1　VLA（π0.5）の成功率。細線は 95% 信頼区間（Wilson）、破線は学習時の正準文を渡したときの成功率。

VLA に渡した文	成功	成功率	95% 区間	1mm 基準でも成功	失敗のうち別の作業をした
学習時の正準文（基準）	28/30	**93%**	79%–98%	77%	0
英語の言い換えをそのまま	67/90	**74%**	65%–82%	63%	19
英語の言い換え → Kotoba-VLA	81/90	**90%**	82%–95%	73%	0
日本語 → LLM で英訳しただけ	81/90	**90%**	82%–95%	77%	6
日本語 → Kotoba-VLA	84/90	**93%**	86%–97%	77%	0

英語の遠回しな言い換え（例：「place the spreadable dairy product into the mixing vessel」）をそのまま渡すと成功率は 74% に下がり、失敗 23 件のうち 19 件では、頼んでいない別のスキルのゴールを満たしていた（クリームチーズを頼んだのにボウルを皿へ、など）。PARC2026 の本番で見た「別の器を運ぶ」型の失敗が、LIBERO-Goal でも再現された。言語ブリッジを通すと成功率は 90% に戻り、別の作業をしてしまう失敗は 0 件になった。対応のある比較（同じスキル・初期状態・元の文）では、ブリッジだけが成功した組が 20 件、そのままだけが成功した組が 6 件で、McNemar の正確検定で $p = 0.009$ だった。
一方、日本語の依頼を Qwen3-8B で英訳しただけでも 90% 成功し、$\pi0.5$ は「put」と「place」のような素直な言い換えには強かった（ブリッジとの差は 9 件対 6 件、$p = 0.61$ で有意ではない）。ただし英訳で失敗した 9 件のうち 6 件は別の作業で、「配膳したいので、器を平皿の上に重ねておいて」が「Place the dishes on top of the serving tray.」と訳されると、3 つの初期状態すべてでボウルを棚の上に置いた（動画のデモ 2）。依頼が遠回しになるほど直訳は危うく、ブリッジは成功率を正準文の水準（93%）にそろえる。ブリッジを通した後の失敗は、正準文でも失敗する組（VLA 自身の動作の失敗）だけである。
なお成功しても対象外の物体を 1mm 以上動かした例は正準文でも 30 件中 5 件あり（例：皿を押すときにクリームチーズに触れる）、言葉では解決できない、VLA 側の課題として残る。

4.3 複数ステップの依頼

2〜3 個の作業を含む日本語の依頼 6 件を、それぞれ 3 つの初期状態で実行した（計 18 試行）。比較対象は、スキルの間で姿勢を戻さず、失敗しても再試行しない素朴な連続実行である。

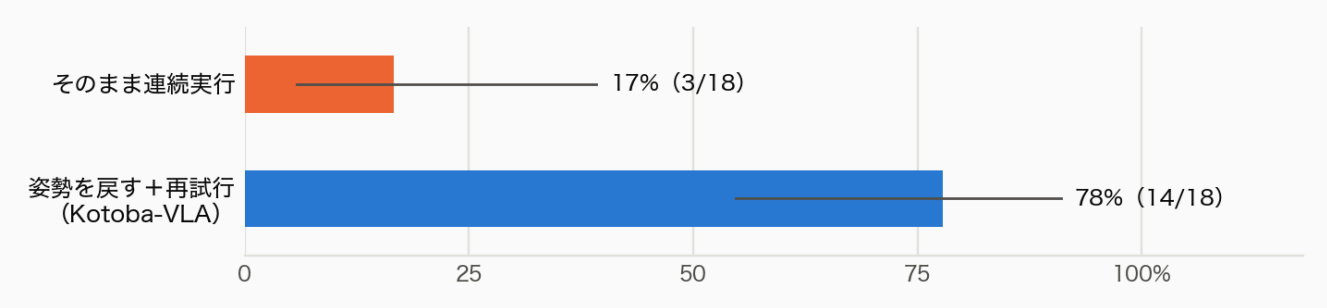


図 2　複数ステップ依頼の完遂率（全スキルのゴール達成）。

スキルの間でアームを初期姿勢へ戻し、失敗したら 1 回再試行すると、18 試行中 14 試行で依頼を最後までやり切った（スキル単位では 39 個中 32 個）。戻さずに続けると 3 試行に留まり、失敗の多くは 2 番目のスキルで起きた。前のスキルが終わった姿勢は VLA の学習時の初期姿勢から外れているため、姿勢の“分布のずれ”が言葉のずれと同じように効いている。再試行で救えたのは 1 件で、残る失敗は最初のスキル自体が正準文でも失敗する組（2 件）と、「クリームチーズを入れたボウルを皿へ」のように前の作業で物体の状態が変わる組だった。後者は姿勢を戻さない方が成功しやすく（2/3 対 1/3）、常に戻すのが最善とは限らない。

5. 工夫した点

- **VLA を再学習せずに言葉の側を合わせた。**LLM にはスキル ID しか選ばせないので、VLA に届く文字列は必ず学習時の正準文になる。新しい言い回しに出会うたびに VLA を学習し直す必要がない。
- **PARC2026 の資産を「再現できる形」で持ち込んだ。**公開 π0.5 と自作 LoRA から最終提出 T1 の重みを焼き直し、SHA-256 の一致で同一性を示した。推論経路も提出時と同じにし、PARC で 0 点を出した落とし穴（重みが黙って読み込まれない、正規化統計が空になる）を起動時に値で検査する。
- **公平な比較を作った。**同じスキル・同じ初期状態・同じ乱数で、VLA に渡す文だけを変えた。英語の言い換えを評価するときはその文を検索キーと LLM の例文から外し、プロンプト調整に使っていない依頼文で確証した。
- **失敗の中身を測った。**成功率だけでなく、対象外の物体が 1mm 以上動いたか（PARC の採点基準）と、頼んでいない別のスキルのゴールを満たしてしまったか（言葉の取り違え）を記録した。
- **1 シーンで複数のスキルをつなげた。**LIBERO-Goal の 10 タスクは物体と配置が共通なので、ゴール述語を差し替えて同じ環境で判定し、スキルの間でアームを初期姿勢へ戻して VLA の学習分布に近い状態から次のスキルを始める。
- **できないことは断る。**スキル一覧で実現できない依頼は近いスキルに丸めず、理由を添えて断る。音声認識が依頼を聞き違えた場合も、無理に実行しない側に倒れた。
- **すべてローカルで動かした。**音声認識・埋め込み・LLM は MLX、VLA は MPS（fp32）で推論し、外部 API を使っていない。3 つのプロセスに分けたので、版の衝突する依存を同居させずに済んだ。

6. 考察・限界・今後

- **言葉の正規化は「学習し直さない適応」として有効。**PARC2026 では言い回しのずれを LoRA 学習で埋めようとして本番で伸び悩んだが、入力側で正準文に揃えるだけで、遠回しな英語の依頼の成功率を 74% から 90% に戻せた。学習の前に入力の分布を合わせる、という順番は PARC の教訓（規約一致が最も効く）とも一致する。
- **限界 1：スキルの語彙の外には出られない。**正準文に無い作業（例：「ボウルを引き出しから出す」）は、断ることはできても実行はできない。PARC の Track3（逆向きの作業）が 0 点だったのと同じ壁である。断った依頼を記録して学習データ収集の候補にする「データフライホイール」が次の一歩になる。
- **限界 2：評価はシミュレータ内の 1 シーン（LIBERO-Goal、10 スキル）。**初期状態も各 3 通りで、統計的な差が示せたのは英語の言い換えの比較だけである。成否判定もシミュレータの真値（BDDL 述語）を使っており、実機では VLM による成否判定などに置き換える必要がある。
- **限界 3：音声はすべて合成音声。**実際の人の声・雑音・言い淀みでの音声認識の誤りは未評価。ただし誤認識した依頼を無理に実行せず断る挙動は確認できた。
- **今後。**実機（SO-101 など）への移植、他シーン（LIBERO-10 の長い作業）への拡張、dora-rs によるノード構成（シミュレータ側が Python 3.10 に固定されているため今回は見送った）、物体状態の変化を考慮したスキル間の姿勢の選び方。

7. 講義との対応

講義	本課題での対応
第1・2回 MLOps / RobOps	評価条件の固定（乱数・初期状態）、開発セットと未使用セットの分離、pytest による検査、結果 JSON の版管理
第3回 計算機の底	MPS での fp32 推論（約 14GB）と bf16 の不具合回避、HTTP＋msgpack による観測（画像 2 枚＋状態）の受け渡し、各段の遅延計測
第4・5回 ROS 2・LeRobot	処理をプロセス（ノード）に分けて通信でつなぐ構成、LeRobot の π0.5 推論経路と LoRA
第6回 オープンソース	LIBERO・robosuite・MuJoCo・lerobot・Qwen・Whisper を組み合わせ、ライセンスを README に明記

8. 再現方法と提出物

コード一式は GitHub（https://github.com/masuhama2147-svg/kotoba-vla）にある。環境構築・重みの再構成（SHA-256 照合）・評価・動画生成の手順は README にまとめた。 評価の生ログと集計は `results/` に置いた。動画の実行シーンは 2 倍速で再生している（動画内に明記）。

使用した主な OSS：LIBERO / hf-libero（MIT）、robosuite・MuJoCo（Apache-2.0）、lerobot（Apache-2.0）、π0.5 の重み（Physical Intelligence / lerobot。PaliGemma 由来部分は Gemma 利用規約）、 Qwen3・Qwen3-Embedding（Apache-2.0）、Whisper（MIT）。言い換え文は LIBERO-plus の公開データに由来する。